Indice

Interfaccia e utilizzo

SimpleID3 è un JAR eseguibile dopo aver installato JDK o JRE sul proprio computer windows. Il tool permette di estrapolare le informazioni ID3v1 con varie modalità

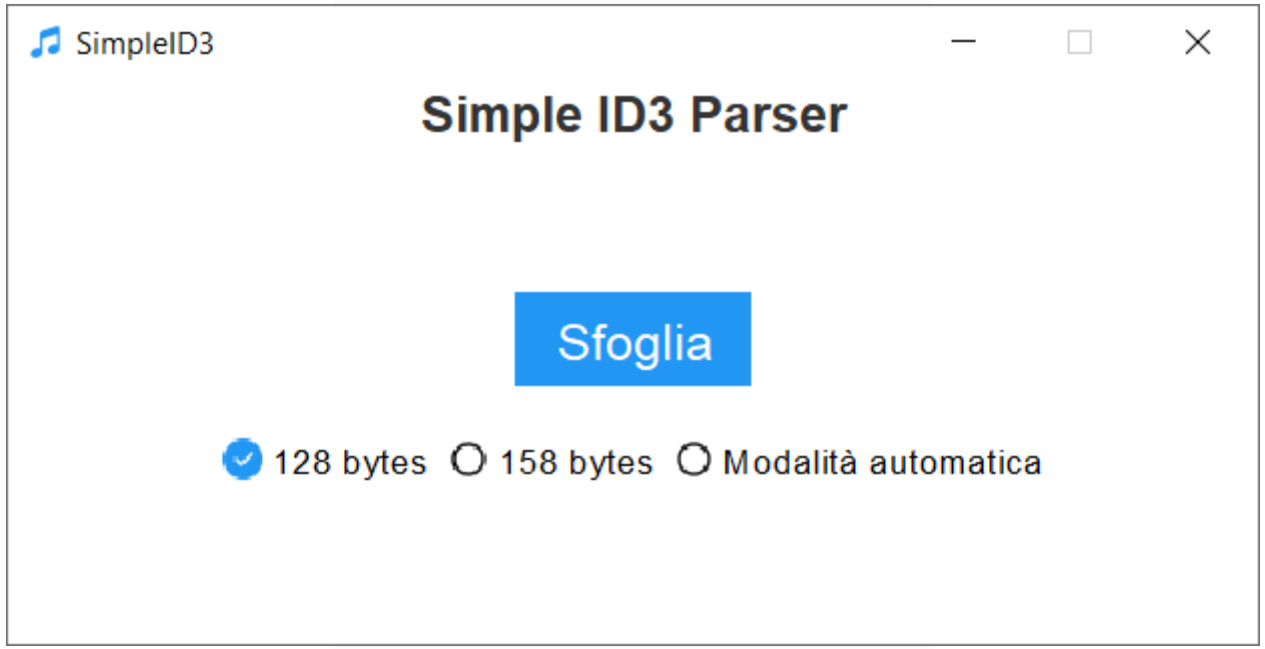

Interfaccia e utilizzo

- Modalità 128byte -> il tool estrae gli ultimi 128byte del file mp3 indifferentemente dal loro contenuto. È la modalità più rapida, visto che le informazioni ID3v1 sono quasi sempre alla fine del file mp3, ma può avere problemi in caso di tag non conformi allo standard (+ o – byte presenti) poiché effettua il riconoscimento semantico in un secondo momento
- Modalità 158byte -> come per 128byte, ma vengono utilizzati gli header (vedi parte gestione e controllo errori)
- Modalità automatica -> viene parsato tutto il file mp3 alla ricerca dell'inizio delle informazioni ID3v1 segnalate dalla parola «TAG». Può cercare info in tutto il file e non ha problemi di dimensioni non conformi, ma non è altrettanto veloce può talvolta dare qualche errore (poiché parsa tutto l'mp3 come file di testo)

Utilizzo delle modalità

- Selezionata la modalità il tool ci permette di scegliere un file mp3 in qualsivoglia posizione all'interno della memoria di massa della nostra macchina. Ricordiamo che per i classici mp3 la lettura viene effettuata con modalità 128byte o automatica

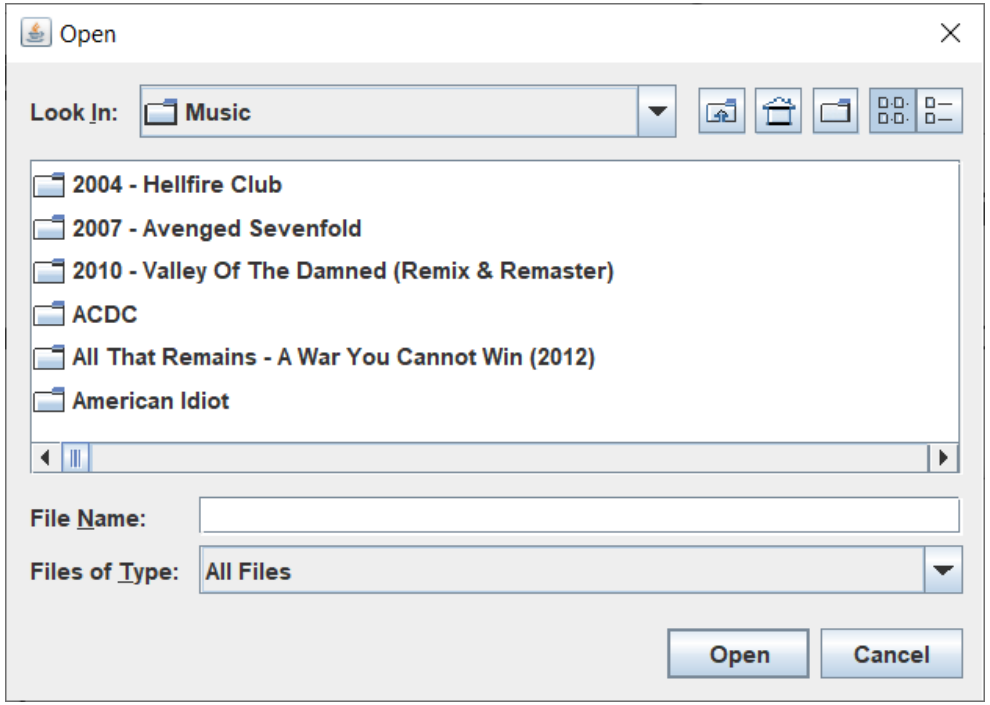

Utilizzo delle modalità

- Infine, a meno di informazioni non conformi allo standard, abbiamo le informazioni visualizzate a schermo

Grammatica utilizzata

- La grammatica utilizzata permette di riconoscere 2 differenti strutture di dati, basate sullo stesso concetto di informazioni ID3v1
- Possiamo anche parsare un'intero file mp3 fino al riconoscimento della struttura principale dell'ID3v1. come slot «musica» indichiamo un qualsivoglia numero di caratteri

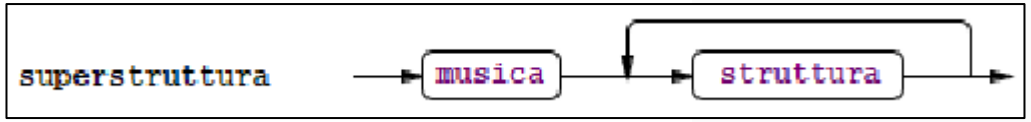

- La struttura è caratterizzata per iniziare sempre con la parola chiave «TAG» qualsiasi sia il suo tipo

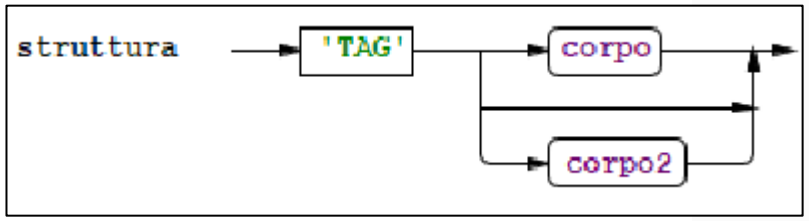


```
superstruttura: musica struttura+;
musica  :       .*;
struttura: 'TAG' (corpo||corpo2);
```

Grammatica senza header

- La grammatica che riconosce l'ID3v1 standard è caratterizzata in corpo2 come segue

- Dove ogni slot è una sequenza di 30 char

```
slot returns [List<Token> p]
@init { p = new ArrayList<Token>();}
        :
        c1=CHAR c2=CHAR c3=CHAR c4=CHAR c5=CHAR c6=CHAR c7=CHAR c8=CHAR c9=CHAR c10=CHAR
        c11=CHAR c12=CHAR c13=CHAR c14=CHAR c15=CHAR c16=CHAR c17=CHAR c18=CHAR c19=CHAR c20=CHAR
        c21=CHAR c22=CHAR c23=CHAR c24=CHAR c25=CHAR c26=CHAR c27=CHAR c28=CHAR c29=CHAR c30=CHAR
        {p.add(c1);p.add(c2);p.add(c3);p.add(c4);p.add(c5);p.add(c6);p.add(c7);p.add(c8);p.add(c9);p.add(c10);
        p.add(c11);p.add(c12);p.add(c13);p.add(c14);p.add(c15);p.add(c16);p.add(c17);p.add(c18);p.add(c19);p.add(c20);
        p.add(c21);p.add(c22);p.add(c23);p.add(c24);p.add(c25);p.add(c26);p.add(c27);p.add(c28);p.add(c29);p.add(c30);}
        ;
```

- Mentre «anno» una sequenza di soli 4 char e «cslot» una variante dello slot mostrato qui sopra creato per leggere senza errori anche le informazioni ID3v1.1 senza però supportare l'informazione della traccia

Grammatica senza header

- La grammatica ID3v1.1 aggiunge al posto degli ultimi due bit dello slot commento, un byte di informazione per il numero di traccia. Questo byte non viene letto come char per far si che le versioni v1.1 possano essere lette anche se non totalmente, al posto degli ultimi due char abbiamo un qualsivoglia carattere

```
c27=CHAR c28=CHAR c29=. c30=.
```

- Il riconoscimento del genere è affidato alla parte Java che elabora l'informazione contenuta nel byte cercandone la corrispondenza. Il problema viene affrontato successivamente nel dettaglio

```
]genere2 returns [Token t]:p=.  {t=p;};
```

Grammatica con Header

- La grammatica con header è pensata per poter individuare eventuali errori all'interno dei dati ID3. si basa sullo stesso standard ma vengono aggiunge delle «parole» all'inizio di ogni slot dati, per un aumento a 158 byte totali
- Gli header sono necessari per poter individuare byte/caratteri mancanti senza che essi vengano «scalati» prendendo il successivo
- Infatti per come è costruito lo standard non c'è differenza tra, ad esempio, lo slot titolo e il suo immediato successivo artista, dove entrambi sono una sequenza non nulla di 30 char
- L'aggiunta di queste parole permette sia di «centrare» gli slot di informazioni anche con byte mancanti sia di individuare errori ben più evidenti come la totale mancanza di uno slot e cosi via…

Grammatica con Header

- Solita struttura dei dati -> 

dove HEAD è sempre uguale a «TAG».
- Struttura del corpo informazioni -> (evidenziamo la sequenzialità degli slot)

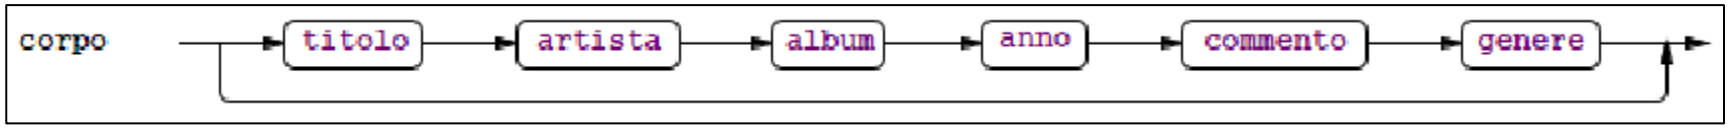

- Struttura del titolo -> (CHAR è ripetuto 30 volte)

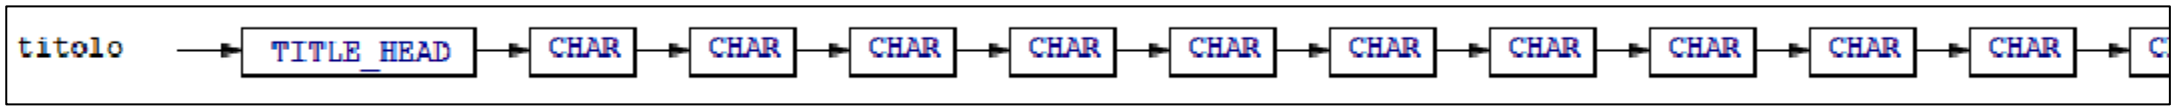

- Tutti gli slot presentano una struttura molto simile con unica variazione la head che le contrassegna

Grammatica con Header

- Esempio di testa per gli slot (prendiamo in esame TITLE_HEAD) ->

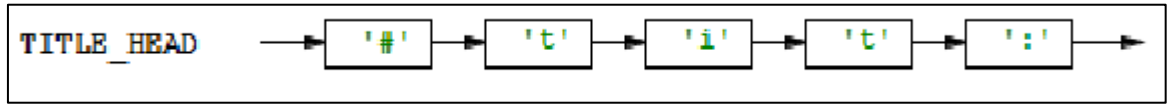

- Ovvero tutti gli header sono anticipati dal carattere #. Questo preclude il suo utilizzo all'interno degli slot dati (infatti è stato escluso dalla definizione di CHAR) per evitare problemi di riconoscimento dei componenti del TAG

- Altri header utilizzati:

Titolo -> #tit
Artista -> #art
Album -> #alb

Anno -> #ann
Commento -> #com
Genere -> #gen

Gestione dei dati con Java

- Una problematica interessante da risolvere è la lettura dei CHAR da parte dell'handler del programma
- Avendo una lunghezza non variabile di 30 caratteri (vuoti ma presenti se non utilizzati) per ad esempio il titolo e l'album bisogna forzare la quantità di CHAR a 30, e rispettivamente recuperare 30 volte il Token nella posizione corretta

```
TITLE_HEAD: '#tit:';
titolo returns [List<Token> p]
@init { p = new ArrayList<Token>();}
  :  TITLE_HEAD
  c1=CHAR c2=CHAR c3=CHAR c4=CHAR c5=CHAR c6=CHAR c7=CHAR c8=CHAR c9=CHAR c10=CHAR
  c11=CHAR c12=CHAR c13=CHAR c14=CHAR c15=CHAR c16=CHAR c17=CHAR c18=CHAR c19=CHAR c20=CHAR
  c21=CHAR c22=CHAR c23=CHAR c24=CHAR c25=CHAR c26=CHAR c27=CHAR c28=CHAR c29=CHAR c30=CHAR
  {p.add(c1);p.add(c2);p.add(c3);p.add(c4);p.add(c5);p.add(c6);p.add(c7);p.add(c8);p.add(c9);p.add(c10);
  p.add(c11);p.add(c12);p.add(c13);p.add(c14);p.add(c15);p.add(c16);p.add(c17);p.add(c18);p.add(c19);p.add(c20);
  p.add(c21);p.add(c22);p.add(c23);p.add(c24);p.add(c25);p.add(c26);p.add(c27);p.add(c28);p.add(c29);p.add(c30);}
  ;
```

Gestione e riconoscimento del frame Genere

- L'informazione del frame contenente il byte non è conforme alla codifica ASCII e pertanto non avendo simboli a disposizione nella grammatica, possiamo solo selezionare il byte e occuparci del riconoscimento in Java tramite l'handler

- Delle 256 combinazioni possibili sono utilizzate solo le prime xxx. Tramite la funzione in Java ci occupiamo del riconoscimento del genere contenuto nel frame
- Esempio di funzione ->

```
GENERE_HEAD:'#gen:';
genere returns [Token t]: GENERE_HEAD p=.
 {t=p;};
```

```
public String riconosciGenere (int i)
{
    switch (i) {
    case 32: return "Blues";
    case 1: return "Classic Rock";
    case 2: return "Country";
    case 3: return "Dance";
    case 4: return "Disco";
        default: return "not recognised";
    }
}
```

Wrapper Java

- L’interfaccia è stata implementata come componente separato dal launcher, utilizzando componenti sia di Java Swing che AWT. Di seguito una breve documentazione dei metodi dell’interfaccia
- `public Interfaccia() throws IOException{` -> costruttore che si occupa di impostare e mostrare tutti i componenti dell’interfaccia. Può lanciare un’eccezione I/O per via della lettura di design personalizzati dell’interfaccia (png)
- `public static void setData(int c, String data) {` -> si occupa di recuperare le informazioni ottenute dall’handler, impostare e mostrare l’interfaccia per la visualizzazione delle informazioni. In base al parametro intero passato viene selezionata la cella dell’interfaccia, mentre la stringa è l’informazione che vogliamo che mostri
- `public String fileChooser() throws NullPointerException` -> mostra il selettore del file da leggere

Wrapper Java

- `private void startParsing(ActionEvent e) {` -> metodo lanciato dal listener sul pulsante «sfoglia», a sua volta si ricollega alla classe ParserLauncher.java per lanciare il selettore del file e le operazioni di visualizzazione delle informazioni
- `public boolean checkMode()` -> metodo per la rilevazione dall'interfaccia della modalità selezionata
- Proseguiamo con i metodi del launcher
- `public static char[] getTagFromFile(String name, int offset) throws FileNotFoundException, IOException` -> si occupa di ricercare all'interno del file nella directory descritta dal parametro stringa, l'inizio delle informazioni ID3 tramite la ricerca di TAG. Successivamente in base all'offset vengono prelevati un numero fisso di Byte e restituiti sotto forma di array di char. La presenza dell'oggetto di tipo FileInputStream può lanciare eccezioni di file non trovato e di problemi di I/O

Wrapper Java

- `public static InputStreamReader setReaderWithStartSearch(Interfaccia a) throws FileNotFoundException, IOException` -> metodo che imposta l'oggetto da dare al parser, con un'operazione intermedia di scrittura su file. Recupera la stringa delle informazioni con il metodo prima descritto, selezionando la directory del file interessato tramite il fileChooser dell'interfaccia e passandogli l'offeset selezionato. In questo metodo il file viene «ritagliato» prendendo un numero di bit a partire dalla posizione di «TAG» pari all'offset. È deprecato all'interno del tool
- `public static InputStreamReader setReaderNoSearch(Interfaccia a) throws FileNotFoundException, IOException` -> imposta l'oggetto da dare dal parser, restituendo tutto il file mp3 selezionato senza modifiche. Viene utilizzato per il riconoscimento con la modalità automatica, dove tutto il file viene parsato
- `public static String setString(Interfaccia a) throws FileNotFoundException, IOException` -> metodo che restituisce la stringa di informazioni ID3, in modo simile al setReaderWithStartSearch ma senza scrivere su un file intermedio. Viene utilizzato per le due modalita 128/158 byte

Wrapper Java

- `public static void avvio(Interfaccia a) throws FileNotFoundException, IOException, RecognitionException {` ->
  metodo richiamato dall'interfaccia che avvia tutto il processo di selezione del file e riconoscimento. In base alla modalità selezionata costruisce il parser in maniera diversa (argomento String o BufferedReader) ed effettua il parsing. Infine a console restituisce la serie di errori trovati se ce ne sono (quest'ultimi non sono visibili dall'interfaccia del tool)
- `public static void main (String[] args) throws FileNotFoundException, IOException, RecognitionException {` ->
  istanzia semplicemente l'interfaccia

Altri dettagli sul wrapper ->

- I file vengono letti con codifica ANSI (`"Cp1252"`) per permettere la lettura dei simboli del genere (che altrimenti finirebbe i simboli intorno al 140esimo)
-

Gestione degli errori (header)

- Vengono effettuati controlli sulla presenza e correttezza degli Header e si controlla che ogni campo contenente le informazioni del brano sia di lunghezza pari a 30 caratteri.
- Sfruttiamo il riconoscimento delle eccezioni di ANTLR per capire che tipo di errore riceviamo durante il parsing
- Alcuni esempi:
  - Mancanza o errata scrittura del TAG iniziale

```
Errori rilevati
1 - Syntax Error 1 at [1, 4]: Found TITLE_HEAD ('tit:') - mismatched input 'tit:' expecting 'TAG'
```

Gestione degli errori nel dettaglio

- Durante lo sviluppo della grammatica ci siamo accorti che senza una chiara distinzione dei frame è molto difficile riuscire a fare una rilevazione dei errori accurata.
- Nello standard ID3 in esame infatti non c'è una chiara distinzione tra il frame Titolo ed il frame Artista, se quindi dovesse mancare un byte nel Titolo la cosa si rifletterebbe nell'Artista e così via a causa della sequenzialità dei dati
- Per ovviare e operare una buona gestione degli errori abbiamo aggiunto allo standard l'utilizzo delle «head» con caratteri unici non utilizzabili all'interno dei frame (in modo da non innescare un riconoscimento di una «testa» in modo da riconoscere il tipo di errore e la sua localizzazione
- Nonostante ciò, la grammatica è pensata per riconoscere automaticamente se stiamo trattando delle informazioni con le «head» oppure senza, evitando di doverlo specificare. L'unica opzionalità è lasciata al metodo con il quale estrapolare i dati dai file

Testing del tool

- Il tool è stato testato utilizzando il pacchetto fornito disponibile sul sito dell'organizzazione ID3 -> https://id3.org/Developer%20Information
- Dei 270 test + extra, il tool riesce a riconoscere correttamente le informazioni in tutti i 270 casi (extra esclusi)
- Sono stati creati alcuni corrispettivi con gli header per testare anche la grammatica alternativa, con buoni risultati durante la prova

Alcuni casi di test

- Errata scrittura di «TAG» (es. -> TaG TA TAGa)

```
Errori rilevati
1 - Syntax Error 1 at [1, 1]: Found CHAR ('T') - mismatched input 'T' expecting 'TAG'
```

```
line 1:2 mismatched character '#' expecting 'G'
Errori rilevati
1 - Syntax Error 1 at [1, 4]: Found TITOLO_HEAD ('tit:') - mismatched input 'tit:' expecting 'TAG'
```

```
Errori rilevati
1 - Syntax Error 1 at [1, 4]: Found CHAR ('a') - no viable alternative at input 'a'
```

- Lunghezza di titolo, artista e album < 30 caratteri

```
Parsing con ANTLR
Handler Inizializzato
Titolo: aaaaaaaaaaaaaaaaaadaaaaaaaaaA<missing CHAR>
Artista: bbbbbbbbbbbbbbbbbdbbbbbbbbbB<missing CHAR>
Album: ccccccccccccccccccccccccccC<missing CHAR>
Anno: 2003
Commento: ddddddddddddddddddddddddddddD
Genere: Blues
Errori rilevati
1 - Syntax Error 1 at [1, 38]: Found CANC - missing CHAR at '#'
2 - Syntax Error 1 at [1, 72]: Found CANC - missing CHAR at '#'
3 - Syntax Error 1 at [1, 106]: Found CANC - missing CHAR at '#'
```

Alcuni casi di test

- Lunghezza di titolo, artista e album > 30 caratteri

```
Parsing con ANTLR
Handler Inizializzato
Titolo: aaaaaaaaaaaaaaaaaadaaacmaaaaaa
Artista: bbbbbbmbbbbbbcbbbbbdbbbbbbbbbb
Album: ccccccccncccccccccccccccccccc
Anno: 2009
Commento: ddddddddddddddddddddddddddddddD
Genere: Blues
Errori rilevati
1 - Syntax Error 1 at [1, 39]: Found CHAR ('A') - extraneous input 'A' expecting CANC
2 - Syntax Error 1 at [1, 75]: Found CHAR ('B') - extraneous input 'B' expecting CANC
3 - Syntax Error 1 at [1, 111]: Found CHAR ('C') - extraneous input 'C' expecting CANC
```

- Carattere mancante in Anno

```
Anno: 200<missing CHAR>
```

```
Errori rilevati
1 - Syntax Error 1 at [1, 117]: Found CANC - missing CHAR at '#'
```

Alcuni casi di test

- Genere mancante o non riconosciuto

```
Genere: not recognised
Parsing completato con successo
```

- Errata scrittura della head di titolo (es. -> tit: #tit #ti: #tito:)

```
Errori rilevati
1 - Syntax Error 1 at [1, 4]: Found TITOLO_HEAD ('tit:') - no viable alternative at input 'tit:'
```

```
line 1:7 mismatched character 'a' expecting ':'
Errori rilevati
1 - Syntax Error 1 at [1, 9]: Found CHAR - missing TITOLO_HEAD at 'a'
2 - Syntax Error 1 at [1, 38]: Found CANC - missing CHAR at '#'
```

```
line 1:6 mismatched character ':' expecting 't'
Errori rilevati
1 - Syntax Error 1 at [1, 8]: Found CHAR - missing TITOLO_HEAD at 'a'
```

```
line 1:7 mismatched character 'o' expecting ':'
Errori rilevati
1 - Lexical Error 0 at [1, 9]: Found SCAN_ERROR (':') - mismatched input ':' expecting TITOLO_HEAD
```

Fine

UNIVERSITÀ
DEGLI STUDI
DI BERGAMO